BỘ GIÁO DỤC VÀ ĐÀO TẠO

TRƯỜNG ĐẠI HỌC SƯ PHẠM THÀNH PHỐ HỒ CHÍ MINH

KHOA CÔNG NGHỆ THÔNG TIN

ĐỀ TÀI

PNEUMONIA CLASSIFICATION USING X-RAY IMAGE

Sinh viên thực hiện: Lê Đức Anh – 49.01.104.002

Cao Huỳnh Minh Quân – 49.01.104.119

GVHD: TS. Ngô Quốc Việt

TP. Hồ Chí Minh, Ngày 10 Tháng 12 Năm 2025

Lời cảm ơn

Em xin gửi lời cảm ơn chân thành đến thầy **Ngô Quốc Việt** đã tận tình giảng dạy và hướng dẫn các kiến thức cơ bản, cần thiết về Máy học và Xử lý Ảnh cũng như việc làm đề tài cuối kì để chúng em có thể đạt kết quả tốt nhất. Nhờ thế mà chúng em sẽ có được nền tảng vững chắc để bước tiếp trong tương lai sau này và đạt được những thành tựu cao hơn. Một lần nữa, chúng em thật sự cảm ơn thầy rất nhiều.

Đặc biệt, em xin gửi lời tri ân đến cộng đồng Kaggle và tác giả Paul Mooney đã cung cấp bộ dữ liệu quý giá *"Chest X-Ray Images (Pneumonia)"*. Nguồn dữ liệu này là nền tảng quan trọng để thực hiện nghiên cứu.

Cuối cùng, em xin bày tỏ lòng biết ơn đến các tác giả và nhóm nghiên cứu đi trước (được liệt kê trong phần Tài liệu tham khảo). Các công trình nghiên cứu về kỹ thuật CLAHE và kiến trúc mạng CNN đã cung cấp cơ sở lý thuyết vững chắc, giúp em định hướng và xây dựng thành công giải pháp cho bài toán.

Tóm tắt

Viêm phổi là một bệnh lý hô hấp nghiêm trọng với tỷ lệ tử vong cao nếu không được phát hiện kịp thời. Mặc dù X-quang lồng ngực là phương pháp chẩn đoán phổ biến, việc phân tích thủ công thường gặp khó khăn do chất lượng ảnh thấp và áp lực quá tải lên đội ngũ y bác sĩ. Đồ án này đề xuất một hệ thống hỗ trợ chẩn đoán viêm phổi tự động sử dụng kỹ thuật Học sâu với mục tiêu tối đa hóa độ an toàn trong sàng lọc y tế.

Nghiên cứu sử dụng bộ dữ liệu "Chest X-Ray Images (Pneumonia)" và tập trung giải quyết hai thách thức chính: chất lượng ảnh kém và mất cân bằng dữ liệu. Về mặt kỹ thuật, nhóm áp dụng phương pháp tiền xử lý ảnh nâng cao kết hợp **Tăng cường tương phản thích nghi** và **Khử nhiễu** để làm nổi bật các đặc trưng bệnh lý. Mô hình được xây dựng dựa trên kiến trúc **Mạng nơ-ron tích chập (Custom CNN)** 3 khối, kết hợp với chiến lược **Cân bằng trọng số (Class Weighting)** để khắc phục việc thiên vị dữ liệu.

Kết quả thực nghiệm trên tập kiểm thử độc lập cho thấy mô hình đạt độ chính xác tổng thể **88%**, với độ nhạy (Recall) đối với lớp bệnh lên tới **94%**. Kết quả này chứng minh tính hiệu quả của quy trình đề xuất trong việc giảm thiểu tỷ lệ bỏ sót bệnh, hứa hẹn tiềm năng ứng dụng như một công cụ hỗ trợ tin cậy cho bác sĩ chẩn đoán hình ảnh.

1. Lý do chọn đề tài

Viêm phổi là một bệnh lý hô hấp nghiêm trọng, là nguyên nhân gây tử vong hàng đầu ở trẻ em và người cao tuổi trên toàn cầu. Việc chẩn đoán sớm và chính xác đóng vai trò then chốt trong điều trị hiệu quả. Hiện nay, chẩn đoán hình ảnh qua X-quang lồng ngực là phương pháp phổ biến nhất.

Tuy nhiên, việc đọc phim X-quang thủ công đối mặt với nhiều thách thức: sự quá tải của bác sĩ chẩn đoán hình ảnh, mệt mỏi khi xử lý số lượng lớn ca bệnh, và đặc biệt là chất lượng ảnh X-quang thường có độ tương phản thấp, nhiễu hạt.

Đề tài này xây dựng hệ thống hỗ trợ chẩn đoán tự động sử dụng học sâu. Mục tiêu là xây dựng mô hình cân bằng tốt giữa độ nhạy (Recall) để không bỏ sót bệnh và độ chính xác (Precision), đồng thời áp dụng các kỹ thuật xử lý ảnh nâng cao để cải thiện chất lượng dữ liệu đầu vào.

2. Phương pháp

2.1. Bộ dữ liệu

Nghiên cứu sử dụng bộ dữ liệu "Chest X-Ray Images (Pneumonia)" từ Kaggle. Dữ liệu bao gồm 2 lớp: NORMAL (Bình thường) và PNEUMONIA (Viêm phổi).

Một thách thức lớn của bộ dữ liệu này là sự mất cân bằng lớp, với số lượng ảnh viêm phổi chiếm đa số (khoảng 74%) so với ảnh bình thường. Điều này dễ khiến mô hình bị thiên vị nếu không có phương pháp xử lý phù hợp.

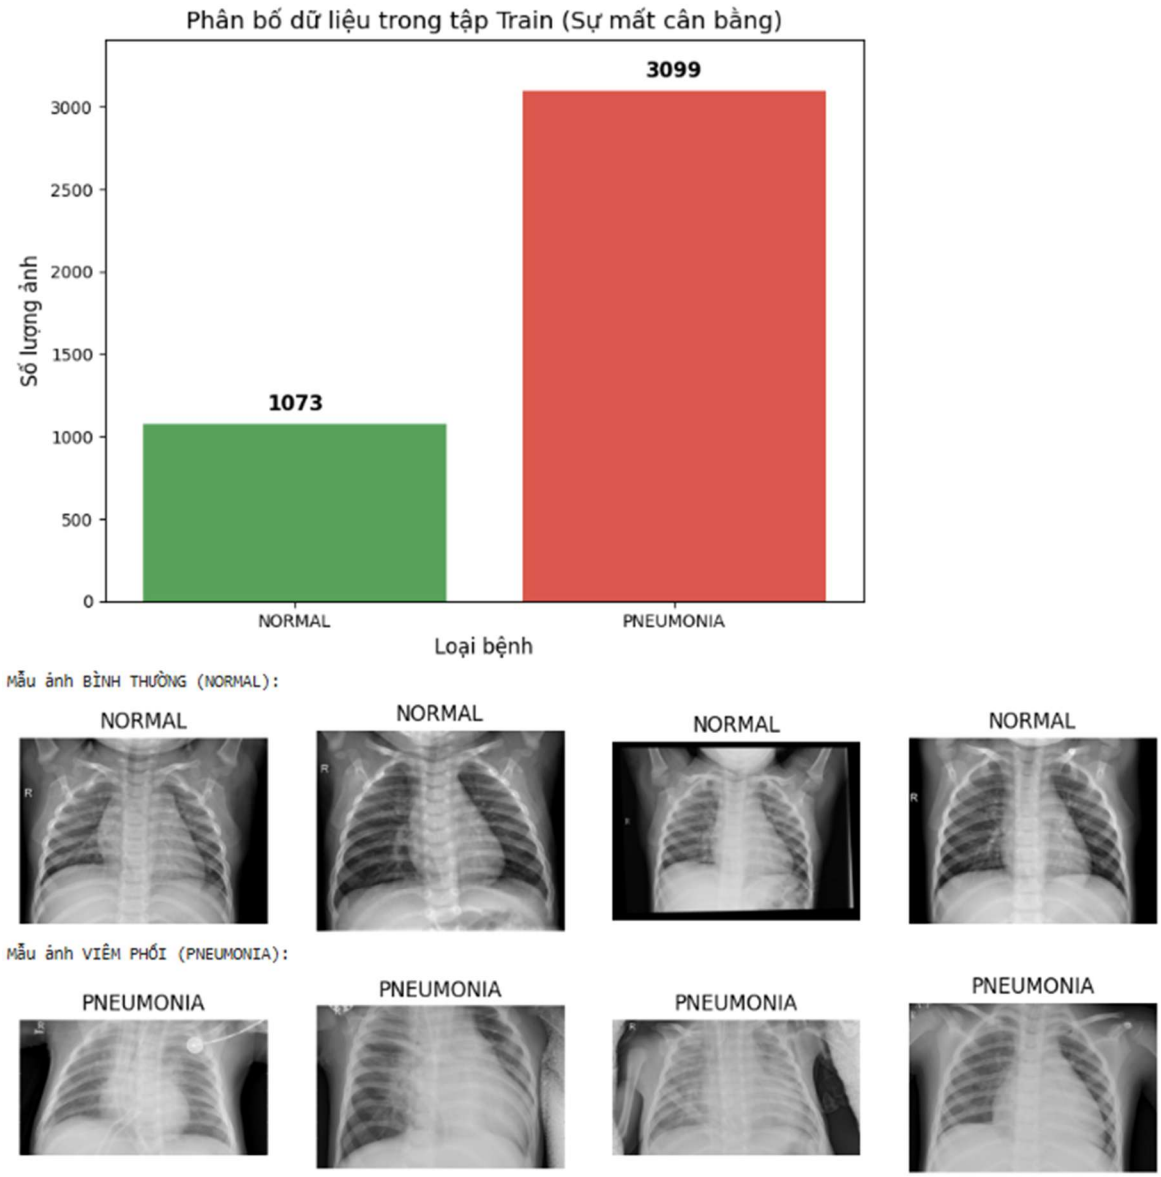

Hình 1: Biểu đồ thể hiện sự chênh lệch số lượng mẫu giữa hai lớp và các ảnh mẫu minh họa NORMAL & PNEUMONIA.

2.2. Tiền xử lý ảnh

Để làm nổi bật các đặc trưng bệnh lý, nhóm thực hiện quy trình xử lý ảnh gồm:

- **Chuyển đổi không gian màu (RGB sang LAB):** Tách biệt kênh độ sáng (L) để xử lý mà không ảnh hưởng thông tin màu.
- **Tăng cường tương phản (CLAHE):** Áp dụng lên kênh L (clipLimit=2.0, lưới 8x8). Kỹ thuật này giúp làm rõ xương sườn và nhu mô phổi bị mờ.
- **Khử nhiễu (Gaussian Blur):** Sử dụng kernel nhỏ (3,3) để loại bỏ nhiễu hạt sinh ra do quá trình tăng tương phản.
- **Chuẩn hóa:** Đưa giá trị pixel về khoảng [0, 1].

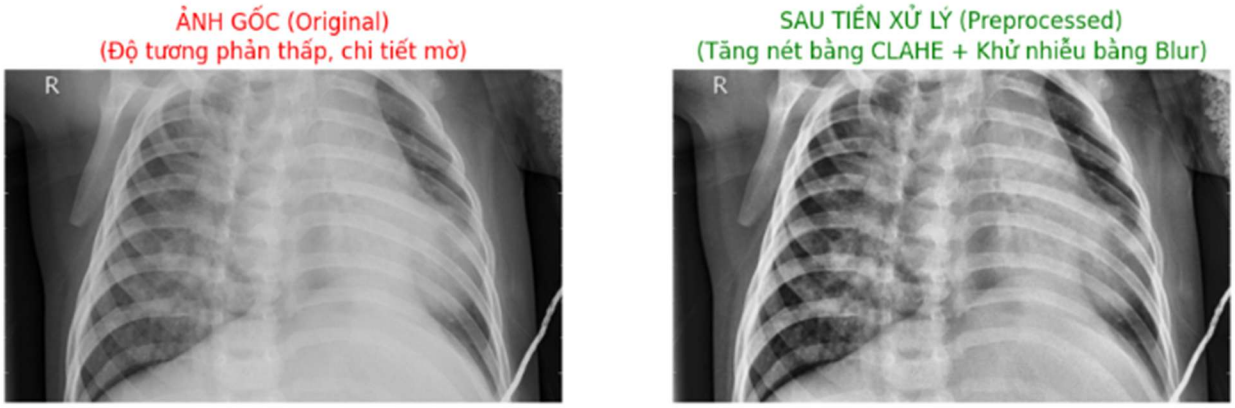

Hình 2: Hiệu quả của CLAHE + Gaussian Blur giúp làm rõ các chi tiết xương và phổi so với ảnh gốc.

2.3. Xử lý mất cân bằng dữ liệu

Nhóm nghiên cứu áp dụng ba kỹ thuật trọng tâm để đảm bảo tính tổng quát hóa và xử lý vấn đề mất cân bằng dữ liệu:

- **Phân chia dữ liệu phân tầng (Stratified Splitting):** Thay vì chia ngẫu nhiên, nhóm sử dụng kỹ thuật Stratified Sampling để tách 20% dữ liệu Train làm tập Validation. Phương pháp này đảm bảo tỷ lệ giữa lớp NORMAL và PNEUMONIA trong cả hai tập là tương đồng, đồng thời giữ cho tập Validation "tinh khiết" (không bị biến dạng bởi Augmentation) để đánh giá trung thực quá trình huấn luyện.
- **Tăng cường dữ liệu (Data Augmentation):** Để khắc phục hạn chế về số lượng ảnh và chống hiện tượng học vẹt, các phép biến đổi ảnh được áp dụng thời gian thực trên tập Train, bao gồm: Xoay ngẫu nhiên (±15°), phóng to/thu nhỏ (10%), dịch

chuyển và lật ngang. Tập Validation và Test chỉ được chuẩn hóa để giữ nguyên tính chất ảnh gốc.

- **Cân bằng trọng số (Class Weighting):** Để giải quyết sự chênh lệch dữ liệu (Pneumonia gấp ~3 lần Normal), nhóm áp dụng trọng số phạt trong hàm mất mát. Cụ thể, lớp thiểu số NORMAL được gán trọng số cao (~1.94) so với lớp đa số PNEUMONIA (~0.67). Điều này ép mô hình phải "chú ý" học các đặc trưng của lớp người bình thường, ngăn chặn xu hướng thiên vị lớp bệnh.

2.4. Kiến trúc Mô hình

Thay vì sử dụng các mô hình huấn luyện sẵn như VGG16 hay ResNet, nhóm quyết định tự thiết kế và xây dựng một kiến trúc CNN. Việc tự xây dựng mô hình giúp nhóm:

- Hiểu sâu sắc cơ chế hoạt động của từng lớp (Conv2D để trích xuất đặc trưng, MaxPooling để giảm chiều dữ liệu, Dropout để chống Overfitting).
- Kiểm soát hoàn toàn độ phức tạp của mô hình, đảm bảo mô hình phù hợp với kích thước dữ liệu hiện có (hơn 5000 ảnh), tránh việc dùng mô hình quá lớn gây lãng phí tài nguyên.

Mô hình được thiết kế theo kiến trúc Custom CNN 3-block để trích xuất đặc trưng tuần tự từ đơn giản đến phức tạp:

- Phần trích xuất đặc trưng: Gồm 3 khối tích chập liên tiếp với số lượng bộ lọc tăng dần: 16 → 32 → 64. Mỗi khối bao gồm:
  - Conv2D: Trích xuất đặc điểm không gian của ảnh.
  - BatchNormalization: Ổn định hóa phân phối dữ liệu, giúp mô hình hội tụ nhanh hơn.
  - MaxPooling2D: Giảm chiều dữ liệu, giữ lại các đặc trưng nổi bật nhất.
- Phần phân loại :
  - Lớp Flatten để duỗi dữ liệu 3D thành vector 1D.
  - Lớp ẩn Dense (64) kết hợp với Dropout (0.3, 0.5) để loại bỏ ngẫu nhiên các liên kết nơ-ron, ngăn chặn hiệu quả hiện tượng Overfitting.
  - Lớp đầu ra Dense (1) sử dụng hàm kích hoạt Sigmoid để trả về xác suất dự đoán (0-1).

3. Thực nghiệm

3.1. Thiết lập huấn luyện

- **Thông số:** Epochs = 20, Batch size = 32, Learning rate = 0.0001, Optimizer = Adam.
- **Callbacks:** Sử dụng ModelCheckpoint (lưu model tốt nhất), EarlyStopping (dừng sớm) và ReduceLROnPlateau (giảm tốc độ học).

3.2. Quá trình hội tụ

Nhóm có thực hiện vẽ biểu đồ accuracy và loss cho train và validation để có cái nhìn tổng quát hơn về mô hình như bên dưới.

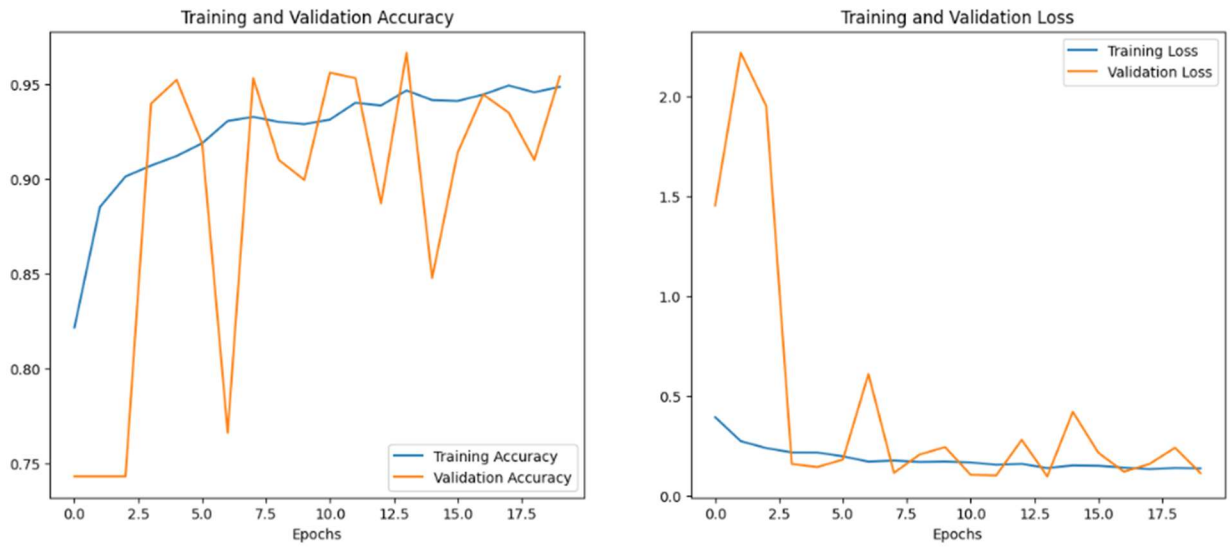

Hình 3: Diễn biến độ chính xác và sai số qua từng Epoch.

Thông qua quan sát biểu đồ huấn luyện, nhóm có rút ra những nhận xét chi tiết sau:

- **Hành trình huấn luyện bền bỉ:** Quá trình huấn luyện kéo dài cho thấy mô hình liên tục tìm kiếm các điểm tối ưu, tận dụng tối đa dữ liệu để tinh chỉnh trọng số.
- **Khả năng tự điều chỉnh:** Ở giai đoạn đầu (Epoch 0-2), biểu đồ Validation Loss có sự biến động cực mạnh (Loss vọt lên cao). Đây là hiện tượng thường gặp khi mô hình bắt đầu làm quen với dữ liệu đa dạng và Learning Rate chưa kịp thích nghi. Tuy nhiên, ngay sau đó (từ Epoch 3 trở đi), mô hình đã thực hiện tự điều chỉnh ấn tượng: Đường Loss giảm sâu nhanh chóng và đi vào quỹ

đạo ổn định. Điều này chứng tỏ kiến trúc mạng có tính bền vững cao, không bị kẹt ở các điểm tối ưu cục bộ tồi tệ.

- **Sự ổn định về sau:** Trong khoảng 3 Epochs cuối cùng, đường Accuracy trên cả tập Train và Validation đều duy trì ở mức cao và bám sát nhau. Sự chênh lệch thấp giữa Train và Validation là minh chứng rõ nhất cho việc mô hình không bị Overfitting, nhờ vào sự hỗ trợ đắc lực của các lớp Dropout và kỹ thuật Augmentation.

Kết luận: Mặc dù khởi đầu có chút khó khăn, mô hình đã hội tụ thành công về trạng thái ổn định với độ chính xác cao và sai số thấp, sẵn sàng cho việc kiểm thử thực tế.

4. Kết quả và đánh giá

Mô hình tốt nhất được đánh giá trên tập Test (624 ảnh). Nhóm nghiên cứu đã tối ưu hóa ngưỡng quyết định lên mức 0.7 để giảm thiểu tỷ lệ báo động giả.

4.1. Hiệu năng tổng thể

Kết quả đạt được rất khả quan với độ chính xác tổng thể là 88%.

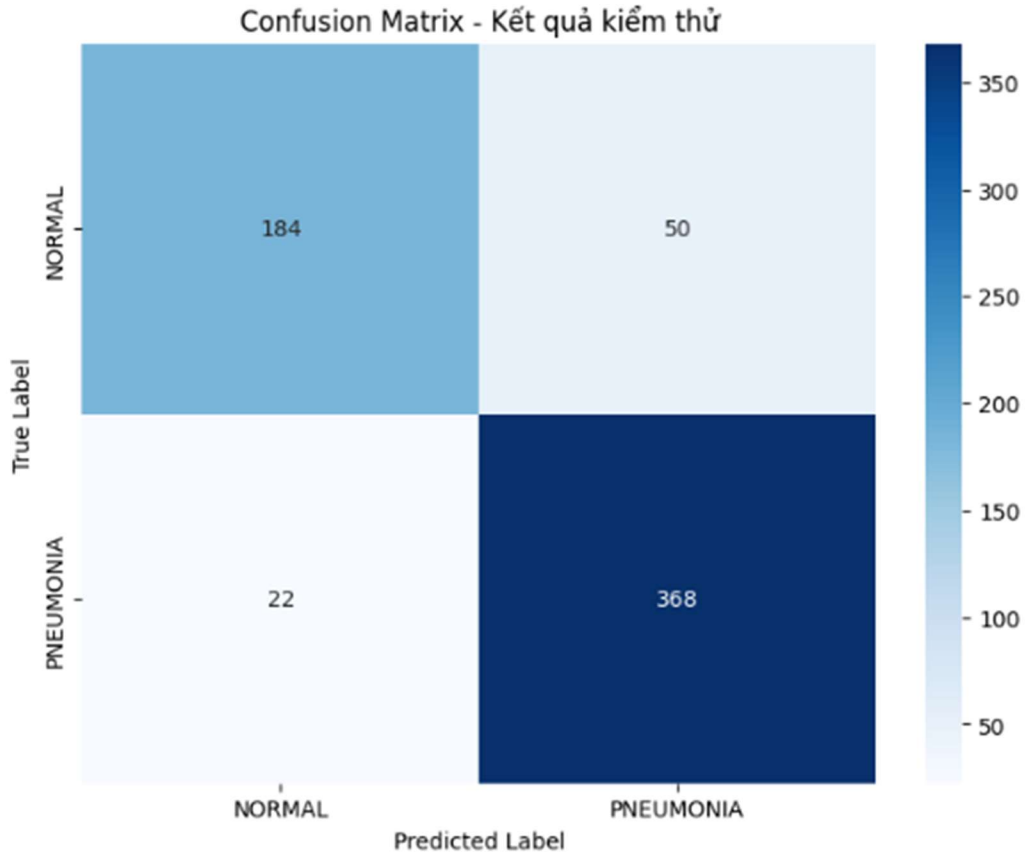


```
--- BÁO CÁO PHÂN LOẠI ---
              precision    recall  f1-score   support

      NORMAL       0.89      0.79      0.84       234
   PNEUMONIA       0.88      0.94      0.91       390

    accuracy                           0.88       624
   macro avg       0.89      0.86      0.87       624
weighted avg       0.89      0.88      0.88       624
```

Hình 4: Ma trận nhầm lẫn và các chỉ số đánh giá chi tiết.

Phân tích số liệu từ Hình 4:

- **Lớp Viêm phổi :** Đạt Recall 0.94. Trong 390 ca bệnh, máy phát hiện đúng 368 ca, chỉ bỏ sót 22 ca. Đây là mức độ an toàn cao cho ứng dụng y tế.

- **Lớp Bình thường :** Đạt Precision 0.89. Tỷ lệ báo nhầm đã được kiểm soát khá tốt (chỉ 50 ca), giúp giảm tải áp lực kiểm tra lại cho bác sĩ.

4.2. Phân tích sai số

Để hiểu rõ hơn về các trường hợp mô hình dự đoán sai, nhóm đã trích xuất và trực quan hóa một số ca điển hình (False Positives và False Negatives).

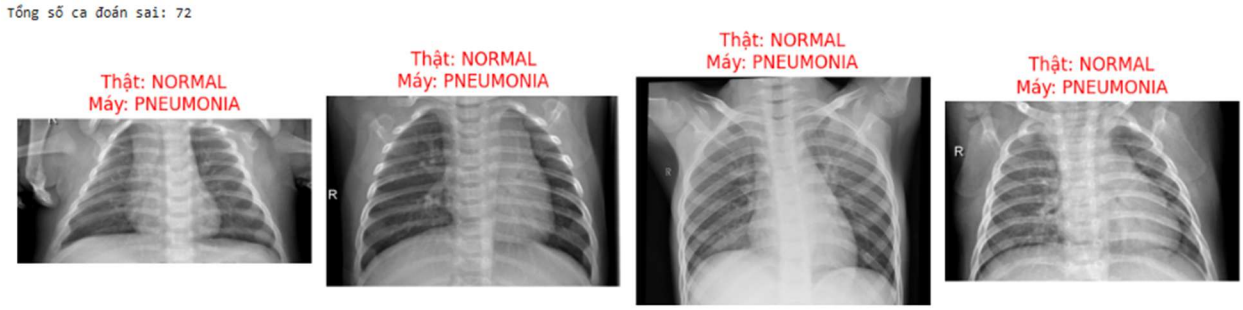

Hình 5: Các trường hợp mô hình dự đoán sai giữa nhãn thực tế và dự đoán.

Thảo luận:

- Các ca **Âm tính giả:** Thường rơi vào các ảnh có vùng viêm phổi nằm ở vị trí khuất sau xương đòn hoặc tim, hoặc vết mờ quá nhạt khiến mô hình khó phân biệt với nhiễu.
- Các ca **Dương tính giả:** Thường là các ảnh X-quang của người bình thường nhưng có chất lượng chụp kém, độ tương phản thấp hoặc có các dị vật (dây dẫn, máy tạo nhịp tim) gây nhiễu loạn đặc trưng ảnh.

5. Kết luận

5.1. Tổng kết thành quả nghiên cứu

Đồ án đã xây dựng và hoàn thiện thành công quy trình chẩn đoán viêm phổi tự động khép kín trên ảnh X-quang lồng ngực. Kết quả thực nghiệm trên tập kiểm thử độc lập cho thấy mô hình đạt độ chính xác tổng thể 88% và độ nhạy đối với lớp bệnh lên tới 94%.

Những con số này là minh chứng cho tính đúng đắn của các chiến lược kỹ thuật đã áp dụng:

- Kỹ thuật tiền xử lý CLAHE kết hợp Khử nhiễu đã cải thiện đáng kể chất lượng đặc trưng đầu vào.
- Chiến lược Cân bằng trọng số (Class Weights) và Phân chia dữ liệu phân tầng (Stratified Split) đã giải quyết triệt để vấn đề mất cân bằng dữ liệu, giúp mô hình không bị thiên vị và đạt độ ổn định cao.

5.2. Ý nghĩa thực tiễn và Hạn chế

Với độ nhạy 94%, hệ thống đáp ứng tốt tiêu chí quan trọng nhất trong sàng lọc y tế là "An toàn", giảm thiểu tối đa nguy cơ bỏ sót bệnh nhân. Mô hình có tiềm năng trở thành công cụ hỗ trợ đắc lực giúp giảm tải áp lực cho bác sĩ chẩn đoán hình ảnh.

Tuy nhiên, nghiên cứu vẫn còn một số hạn chế nhất định. Tỷ lệ báo động giả ở nhóm người bình thường tuy đã được cải thiện nhờ tối ưu ngưỡng quyết định nhưng vẫn còn tồn tại. Điều này có thể xuất phát từ việc mô hình tự xây dựng chưa đủ độ sâu để phân biệt các nhiễu ảnh phức tạp (như dây dẫn y tế, xương bả vai che khuất) với các vết mờ bệnh lý.

5.3. Hướng phát triển

Để nâng cao hơn nữa hiệu năng và tính ứng dụng của hệ thống, các hướng nghiên cứu tiếp theo được đề xuất bao gồm:

- **Thử nghiệm Transfer Learning:** Áp dụng các kiến trúc mạng tiên tiến đã được huấn luyện sẵn như VGG16, ResNet50 hoặc DenseNet121. Các mô hình này có khả năng trích xuất đặc trưng mạnh mẽ hơn, hứa hẹn cải thiện độ chính xác trên các ca bệnh khó hoặc bị khuất lấp.
- **Mở rộng dữ liệu:** Thu thập thêm dữ liệu từ các nguồn khác nhau để kiểm chứng khả năng thích nghi của mô hình với các dòng máy chụp X-quang khác nhau.

Tài liệu tham khảo

[1] Paul Mooney. *Chest X-Ray Images (Pneumonia)*. Kaggle Dataset.

[2] Simonyan, K., & Zisserman, A. (2014). "Very deep convolutional networks for large-scale image recognition". *arXiv preprint arXiv:1409.1556*.

[3] Gonzalez, R. C., & Woods, R. E. (2018). *Digital Image Processing* (4th ed.). Pearson.